

Prédiction du Chômage des Diplômés Tunisiens

Projet Machine Learning End-to-End — ENPE 2017 (INS Tunisie)

452 928

individus

14

features

5

modèles

0.651

F1-macro

Contexte & Problématique

Source

INS Tunisie — ENPE 2017

Dataset

452 928 individus, 14 variables

Problème

Classification supervisée — 3 classes

23.7%

des diplômés du supérieur
sont au chômage en Tunisie

0 = Employé

21% du dataset

21%

1 = Chômeur

36% du dataset

36%


2 = Inactif

43% du dataset

43%

Question ML : Peut-on prédire automatiquement le statut d'emploi d'un diplômé tunisien à partir de ses caractéristiques socio-démographiques ?

Pipeline Machine Learning



Tous les notebooks sont commentés avec titres et descriptions Markdown à chaque étape

Analyse Exploratoire — 3 Découvertes Clés

01

Le Paradoxe du Diplôme

Le taux de chômage AUGMENTE avec le niveau d'études — les diplômés du supérieur sont les plus touchés.

23.7%

chômage — diplômés supérieurs

02

Disparités Régionales

Les régions intérieures (Kasserine, Gafsa, Sidi Bouzid) affichent un taux de chômage systématiquement plus élevé.

+15pts

intérieur vs côtier

03

Asymétrie de Genre

Les femmes diplômées cumulent un taux de chômage plus élevé ET un fort taux d'inactivité — groupe vulnérable.

2×

chômage féminin vs masculin


Comparaison des 5 Modèles

Modèle	Accuracy	F1-macro	Recall Chômeur
XGBoost	0.660	0.651	0.651
Logistic Regression	0.626	0.620	0.739
Random Forest	0.621	0.613	0.702
SVM (Linear)	0.629	0.608	0.659
KNN	0.589	0.580	0.596

Métrique principale : F1-macro — équilibre précision/rappel sur les 3 classes déséquilibrées

Feature Importance & Tentative d'Amélioration

Top Features — XGBoost (Gain)



Notebook 06 — Tentative d'Amélioration

⚠️ Approche A — Binaire (Employé vs Non-Employé)
Acc=0.703 F1=0.422

⚠️ Approche B — 3 classes + features avancées
Acc=0.655 F1=0.648

✓ Version originale Phase 4 ← RETENUE
Acc=0.660 F1=0.651

Conclusion : Le modèle 3 classes conserve la richesse analytique du marché du travail tunisien.

Conclusion & Applicabilité

0.651

F1-macro

XGBoost

0.660

Accuracy

sur 65 496 individus réels

0.734

AUC-ROC

pouvoir discriminant

- Pipeline complet de A à Z — 6 notebooks documentés
- Dataset officiel INS Tunisie — données réelles 452 928 individus
- Le paradoxe du diplôme confirmé par Feature Importance (XGBoost)
- $F1=0.651$ cohérent avec la littérature académique (benchmarks 0.62–0.70)

Applicabilité réelle : ANETI · Ministère de l'Emploi · Politiques d'insertion professionnelle ciblées